

WHITEPAPER TÉCNICO · PROVA DE CONCEITO

Motor de Clareza Vocal PT-BR

IA, análise acústica e DSP seletivo
para voz cantada em português brasileiro

VERSÃO 1.0 · SETEMBRO 2026

DOCUMENTO DE VISÃO TECNOLÓGICA E ESTADO DA IMPLEMENTAÇÃO

1. Resumo executivo

O **Motor de Clareza Vocal PT-BR** é uma prova de conceito local em Python para investigar tratamento vocal contextual em português brasileiro cantado. O sistema combina separação de fontes por aprendizado profundo, análise no domínio tempo-frequência, decisão baseada em confiança e processamento digital seletivo.

A proposta não é reconhecer automaticamente fonemas nesta fase. Ela detecta **eventos acústicos candidatos** em regiões associadas a nasalidade, estridência e sibilância, decide quando há evidência suficiente para intervir e preserva o sinal quando a confiança é baixa.

Escopo correto: a implementação atual prova o pipeline e fornece métricas auditáveis. Superioridade comercial, especialização fonética e benefício perceptual dependem de corpus anotado, benchmarks e testes cegos posteriores.

2. Estado atual da PoC

CAPACIDADE	ESTADO	EVIDÊNCIA NA IMPLEMENTAÇÃO
Separação	Entregue	htdemucs real; MPS com fallback automático para CPU
Diagnóstico	Entregue / heurístico	STFT, centroide, energia por banda, contraste, cobertura e confiança
Motor de decisão	Entregue / inicial	Abstenção por silêncio, baixa confiança ou reconstrução não confiável
DSP	Entregue / experimental	EQ regionalizada, compressor, envelopes e presets por intensidade
QC	Entregue / básico	Reconstrução, RMS, sample peak, true peak estimado 4x, correlação e delta espectral
Validação PT-BR	Pendente	Corpus anotado, precisão/recall/F1 e avaliação AB/ABX

Terminologia: a saída é uma *mix processada* ou *versão corrigida*. O termo master exige uma etapa integral de masterização e escuta crítica.

3. Problema de engenharia

Processadores vocais genéricos raramente declaram validação específica para canto em PT-BR. Isso motiva uma hipótese de pesquisa: descritores acústicos e dados representativos podem orientar intervenções mais contextuais do que presets fixos. As frequências variam com intérprete, registro, microfone, arranjo, dinâmica e técnica; portanto, as faixas abaixo são **janelas iniciais de busca**, não equivalências fonéticas.

FENÔMENO	JANELA INICIAL	RISCO NA MIX	ESTADO
Ressonâncias candidatas à nasalidade	600 Hz-1,2 kHz	Coloração fechada e perda de definição	DSP ativo
Estridência em vogais abertas e belt	2-4 kHz	Fadiga e competição com caixa/guitarras	DSP ativo
Sibilância e fricativas	4-9 kHz	Aspereza e excesso de alta frequência	DSP ativo

3.1 Limite fonético

Energia em uma banda não identifica por si só /ã/, /õ/, /s/ ou /■/. Estudos acústicos de vogais nasais do português brasileiro descrevem estrutura temporal, formantes, antiformantes e variação entre falantes. A heurística atual deve ser entendida como detector de candidatos; um diagnóstico fonema-específico exigirá alinhamento ou modelo acústico treinado para canto.

3.2 Regra de segurança

Cada banda recebe um score de confiança derivado de energia relativa, contraste e cobertura temporal. O motor se abstém quando o score fica abaixo do limiar, quando o stem vocal está abaixo de -55 dBFS RMS ou quando a soma dos stems falha no teste global de reconstrução.

Princípio de projeto: uma intervenção evitada é preferível a uma correção agressiva sem evidência. Controles independentes permitem desligar nasalidade, estridência ou sibilância.

4. Arquitetura híbrida implementada

1. Isolamento por IA

O Demucs gera *vocals* e *no_vocals* com o modelo htdemucs. O sistema tenta MPS, repete em CPU quando necessário e restaura sample rate, duração e canais da entrada.

2. Análise MIR e diagnóstico

O Librosa calcula STFT, centroide espectral, energia por banda, picos dominantes e regiões sustentadas. Janelas temporais distintas refletem a diferença entre vogais prolongadas e fricativas curtas.

3. Motor de decisão

Regras parametrizadas transformam descritores em regiões candidatas, score de confiança e autorização de intervenção. A reconstrução pré-DSP deve apresentar erro RMS relativo de até -15 dB e similaridade normalizada mínima de 0,95.

4. Tratamento DSP seletivo

O Pedalboard cria variantes processadas com filtros paramétricos e compressor. Envelopes de ataque/release e crossfades NumPy aplicam cada variante apenas durante eventos autorizados. Os presets Suave, Balanceado e Intenso alteram ganho, Q, threshold, ratio e wet mix.

5. Recombinação e controle de qualidade

Vocal processado e acompanhamento são somados em float32. A saída recebe proteção de true peak estimado em 4x com alvo de -1 dBTP e relatório de sample peak, RMS, correlação estéreo, delta RMS e variação do centroide. A estimativa não substitui medidor certificado BS.1770.

Auditoria: a interface disponibiliza mix processada, vocal antes/depois do DSP, instrumental, módulos ativos e diagnóstico JSON.

5. Pipeline de processamento




Figura 1. Fluxo lógico atual. O acompanhamento permanece fora do DSP vocal; o motor de decisão pode se abster antes da intervenção.

A separação reduz interferência instrumental na análise, mas pode introduzir artefatos. Por isso, reconstrução e escuta dos stems fazem parte do contrato do pipeline.

6. Viabilidade em Apple Silicon

A execução local em Apple Silicon está demonstrada na PoC. O backend MPS direciona operações compatíveis à GPU integrada, enquanto Librosa, SciPy e Pedalboard permanecem majoritariamente na CPU. Disponibilidade de MPS não implica aceleração integral: cobertura de operadores, memória unificada, modelo e duração do áudio afetam o resultado.

6.1 Benchmark necessário para a beta

MÉTRICA	COMO MEDIR	ESTADO
Latência / RTF	Mesmo arquivo e parâmetros em CPU e MPS	Pendente como harness reproduzível
Memória	Pico de RAM e memória unificada	Pendente
Reconstrução	Erro RMS relativo e similaridade	Implementado
Separação	SDR/SI-SDR mais escuta cega	Pendente por falta de referência
Robustez	Gênero, sotaque, registro, microfone e compressão	Pendente por corpus

6.2 Controle de qualidade atual

- Abstenção global se a reconstrução dos stems não for confiável.
- Abstenção local por score de confiança e nível mínimo do vocal.
- Proteção de true peak estimado por oversampling 4x, alvo -1 dBTP.
- Preservação de sample rate, duração, canais e exportação WAV float32.
- Oito testes automatizados de DSP, alinhamento, reconstrução e QC.

Limite: ainda faltam loudness integrado conforme ITU-R BS.1770, true peak certificado, detecção automática de artefatos e métricas com stems de referência.

7. Plano de validação e evolução

ETAPA	PERGUNTA	EVIDÊNCIA DE SAÍDA
Dataset	Há diversidade representativa?	Trechos licenciados e anotados por fenômeno, região vocal, sotaque e cadeia de gravação
Deteção	O motor localiza eventos relevantes?	Precisão, recall, F1, calibração da confiança e análise de erros
Processamento	A correção ajuda sem degradar?	AB/ABX, artefatos, naturalidade e preferência de especialistas
Sistema	É rápido e estável no M4?	RTF, memória, falhas, fallback e reprodutibilidade

7.1 Critérios de saída para beta

- Processar WAV/MP3 mono ou estéreo em 44,1 e 48 kHz sem perder sincronismo.
- Registrar confiança e motivo de abstenção para cada módulo.
- Não produzir NaN, clipping acima do alvo ou mudança estrutural de duração.
- Fornecer comparação A/B auditável, stems e relatório de QC.
- Executar um corpus mínimo de 30 gravações PT-BR sem falha bloqueante.
- Concluir avaliação perceptual inicial com protocolo e amostra documentados.

7.2 Próximos incrementos

PRIORIDADE	INCREMENTO	RESULTADO
P0	Harness CPU x MPS e telemetria local	RTF e memória reproduzíveis
P0	Corpus piloto e ferramenta de anotação	Calibração de confiança e falsos positivos
P1	Loudness BS.1770 e QC espectral por bandas	A/B mais rigoroso
P1	Chave A/B sincronizada e teste cego	Avaliação perceptual consistente
P2	Detector acústico treinado para canto PT-BR	Evolução além das heurísticas

8. Vantagem competitiva e limites

A diferenciação não está apenas em Demucs, Librosa ou Pedalboard, que são acessíveis a terceiros. O ativo potencial está na combinação de dados licenciados de canto em PT-BR, critérios acústicos calibrados, motor de decisão, experiência de uso e histórico de avaliações perceptuais. Um moat só existe quando esses elementos demonstram desempenho difícil de reproduzir.

Principais limites

- Separação de fontes pode criar artefatos e alterar transientes.
- Bandas de frequência não equivalem automaticamente a fonemas.
- Sotaque, técnica vocal e intenção estética impedem regras universais.
- True peak atual é estimado; loudness integrado e ABX ainda são roadmap.
- Uma correção mensurável pode não ser artisticamente desejável.

9. Conclusão

O Motor de Clareza Vocal PT-BR já demonstra um pipeline modular e auditável: isolamento, diagnóstico, confiança, DSP seletivo, recombinação e QC básico. A tese de especialização linguística continua sendo uma hipótese de produto. O próximo salto de valor depende de dados representativos e testes cegos que comprovem benefício sem perda de naturalidade.

Síntese: a PoC prova o pipeline; os testes medem engenharia; dados e avaliação perceptual deverão provar qualidade e diferenciação.

Referências técnicas essenciais

1. Défossez, A. *Hybrid Spectrogram and Waveform Source Separation*. arXiv:2111.03600, 2021. arxiv.org/abs/2111.03600
2. McFee, B. et al. *librosa: Audio and Music Signal Analysis in Python*. Proceedings of SciPy, 2015. DOI 10.25080/Majora-7b98e3ed-003.
3. Spotify. *Pedalboard: Python Audio Effects Library*. spotify.github.io/pedalboard
4. PyTorch. *MPS backend documentation*. docs.pytorch.org/docs/stable/notes/mps.html
5. Correa, B. T.; Gonçalves, G. F.; Seara, I. C. *Brazilian Portuguese nasal vowels and their acoustic moments*. Estudos de Fonética Experimental, XXXI, 2022.
6. ITU-R BS.1770. *Algorithms to measure audio programme loudness and true-peak audio level*.